

# Inferenza Statistica

## Esame del 5 novembre 2012

Tempo a disposizione 2 ore.

1. Sia dato un campione casuale semplice di 5 unità da una popolazione normale di media  $\mu$  e varianza  $\sigma^2$ .

- a. Quale è la distribuzione della statistica campionaria  $W = \frac{5(\bar{Y} - \mu)^2}{S^2}$ , dove  $\bar{Y}$  è la media campionaria e  $S^2$  è la varianza campionaria (corretta)?
- b. Per quale valore di  $c$  si ha  $P(-c \leq S/(\bar{Y} - \mu) \leq c) = 0.95$ ?

### Soluzione

- a. Si consideri il campione  $Y_1, \dots, Y_5$  con  $Y_i \sim N(\mu, \sigma^2)$ ,  $i = 1, \dots, 5$ . È noto che  $\bar{Y} \sim N(\mu, \sigma^2/5)$  e quindi

$$Z = \frac{\bar{Y} - \mu}{\sigma/\sqrt{5}} = \frac{\sqrt{5}(\bar{Y} - \mu)}{\sigma} \sim N(0, 1)$$

Segue che  $Z^2 \sim \chi_1^2$ . Inoltre, poiché il campione proviene da una popolazione normale, risulta  $X = \frac{4S^2}{\sigma^2} \sim \chi_4^2$ . Quindi si ottiene

$$W = \frac{5(\bar{Y} - \mu)^2}{S^2} = \frac{Z^2}{X/4} \sim F(1, 4)$$

essendo il rapporto tra due chi-quadrato indipendenti divise per i loro gradi di libertà.

- b. Occorre determinare  $c$  tale che

$$0.95 = P\left(-c \leq \frac{S}{\bar{Y} - \mu} \leq c\right) = P\left(\frac{S^2}{(\bar{Y} - \mu)^2} \leq c^2\right) = P\left(\frac{S^2}{5(\bar{Y} - \mu)^2} \leq \frac{c^2}{5}\right) = P\left(\frac{1}{W} \leq \frac{c^2}{5}\right)$$

Da  $W \sim F(1, 4)$  si ricava  $1/W \sim F(4, 1)$  e quindi occorre determinare  $c$  tale che

$$\frac{c^2}{5} = f_{0.95, 4, 1}$$

dove  $f_{0.95, 4, 1}$  è il quantile 0.95 della F di Fisher con 4 ed 1 gradi di libertà che soddisfa  $P(F \geq f_{0.95, 4, 1}) = 0.05$ ; dalle tavole si ricava  $f_{0.95, 4, 1} = 224.5$ . Pertanto  $c = \sqrt{224.5 \cdot 5} \approx 33.5$ .

2. Si supponga per  $Y$  una distribuzione bernoulliana  $Be(p)$ . Di solito è di grande interesse la quantità  $\text{logit}(p) = \log \frac{p}{1-p}$ .

- a. Sapreste fornire uno stimatore di massima verosimiglianza per  $\text{logit}(p)$  a partire da un campione di  $n$  elementi tratti da  $Y$ ?
- b. Per un campione numeroso da  $Y$  fornire l'espressione approssimata per la varianza dello stimatore ottenuto al punto sopra.

### Soluzione

- a. La funzione di log-verosimiglianza del campione è

$$\begin{aligned} \log f(y_1, \dots, y_n; p) &= l(p) = \log \left[ \prod_{i=1}^n p^{y_i} (1-p)^{1-y_i} \right] \\ &= \sum_i y_i \log(p) + \left( n - \sum_i y_i \right) \log(1-p) \end{aligned}$$

Lo stimatore di massima verosimiglianza per  $p$  si ottiene eguagliando a zero la funzione *score*

$$\frac{1}{p} \sum_i y_i - \left( n - \sum_i y_i \right) \frac{1}{1-p} = 0.$$

Risolvendo rispetto a  $p$  si trova  $\hat{p} = \frac{\sum_i y_i}{n} = \bar{y}$ . Per la proprietà di equivarianza degli stimatori di massima verosimiglianza

$$\widehat{\text{logit}(p)} = \log \frac{\hat{p}}{1-\hat{p}}$$

- b.** Posto  $\psi = g(p) = \log \frac{p}{1-p}$ , dal punto precedente si è ottenuto  $\hat{\psi}_{MV} = \log \frac{\bar{Y}}{1-\bar{Y}}$ . La distribuzione campionaria asintotica per  $\psi$  si ricava considerando la distribuzione asintotica dello stimatore di MV,  $\hat{p}$ , e applicando il metodo delta per ricavare la varianza asintotica

$$\hat{p} \sim N \left( p, \frac{p(1-p)}{n} \right),$$

si ha

$$\widehat{\text{logit}(p)} = \hat{\psi}_{MV} \sim N \left( \psi, [g'(p)]^2 \frac{p(1-p)}{n} \right)$$

dove

$$g'(p) = \frac{d}{dp} \log \frac{p}{1-p} = \frac{1}{p(1-p)}$$

Pertanto l'espressione approssimata per la varianza dello stimatore di massima verosimiglianza del parametro  $\psi$  è

$$\frac{1}{p^2(1-p)^2} \cdot \frac{p(1-p)}{n} = \frac{1}{np(1-p)}$$

e la sua distribuzione asintotica è

$$\widehat{\text{logit}(p)} = \hat{\psi}_{MV} \sim N \left( \log \frac{p}{1-p}, \frac{1}{np(1-p)} \right).$$

- 3.** Un'apparecchiatura elettronica ha una componente il cui tempo di rottura (in giorni) è assimilabile ad una variabile casuale esponenziale  $X$  di media  $\lambda$ . Quando si verifica una rottura la componente viene sostituita. In magazzino sono conservati 19 componenti di riserva.

- a.** Supponendo  $\lambda = 20$ , si determini la probabilità che la componente duri oltre 25 giorni essendo noto che per i primi 10 giorni la componente non si è rotta.
- b.** Determinare la probabilità che l'apparecchiatura venga mantenuta in funzione per più di 1 anno dopo che la prima componente viene sostituita.
- c.** Determinare la probabilità che in 10 giorni si rompa più di una componente.

### Soluzione

- a.** Il tempo di rottura  $X$  è tale che  $X \sim \text{Esp}(1/20)$ . La probabilità cercata è  $P(X > 25 | X > 10)$ . Per una variabile aleatoria esponenziale vale la proprietà di assenza di memoria, ne segue che

$$P(X > 25 | X > 10) = P(X > 15) = e^{-15/20} = 0.47$$

- b. Sia  $Y = \sum_{i=1}^{19} X_i$ , dove  $X_i$  è la durata dell' $i$ -esima componente distribuita secondo un'esponenziale di parametro  $\theta = 1/20$ . 19 componenti sono sufficienti per un anno se la somma delle loro durate supera 365 giorni. La probabilità che l'apparecchiatura venga mantenuta in funzione per oltre un anno è  $P(Y > 365)$ . La somma di  $n = 19$  esponenziali di parametro  $\theta = 1/20$  è distribuita secondo una gamma di parametri  $n$  e  $\theta$ .

Per il Teorema del limite centrale possiamo approssimare la distribuzione di  $Y$  con una normale di media  $n/\theta = 19 \times 20$  e varianza  $n/\theta^2 = 19 \times 20^2$ . Otteniamo così

$$P(Y > 365) \approx 1 - \Phi\left(\frac{365 - 19 \cdot 20}{20\sqrt{19}}\right) = 0.5683$$

- c. Sia  $V$  il numero aleatorio di guasti in 10 giorni che richiedono la sostituzione della componente con un pezzo di ricambio e  $T$  il tempo fino alla seconda rottura. Allora  $Y \sim Po(1/2)$  e  $T \sim Erlang(2, 1/20)$ . La probabilità cercata è la probabilità che i guasti in 10 giorni siano almeno due:

$$P(T \leq 10) = P(Y \geq 2) = 1 - [P(Y = 0) + P(Y = 1)] = 1 - \sum_{j=0}^1 \frac{(1/2)^j}{j!} e^{-1/2} = 0.09$$

4. La lunghezza in cm del fusto di piante adulte  $Y$  è distribuita normalmente con varianza 64. Si ottiene un campione di 16 alberi e si decide di rifiutare l'ipotesi nulla  $H_0 : \mu = 55$ , contro l'ipotesi alternativa che la lunghezza media sia superiore a 55 cm, utilizzando quale regione di accettazione  $A = \{(y_1, \dots, y_n) : \bar{y} \leq 57.5\}$ .

- a. Quanto vale il livello di significatività del test,  $\alpha$ ?  
b. Supponendo di non conoscere  $\bar{y}$  e sapendo che il livello di significatività osservato è risultato pari a 0.37, qual era la media del campione?  
c. Per quale valore di  $\mu$  in  $H_1$  la potenza del test risulta pari a 0.8?

### Soluzione

- a. La regione di rifiuto è  $\bar{y} > 57.5$ , dove  $\bar{y}$  è la media campionaria ottenuta da un campione di numerosità 16. Quindi si ricava

$$\begin{aligned} \alpha &= P(\bar{Y} > 57.5 | \mu = \mu_0) \\ &= P\left(Z > \frac{57.5 - \mu_0}{\sigma/\sqrt{n}}\right) \\ &= 1 - \Phi\left(\frac{57.5 - 55}{8/\sqrt{16}}\right) = 1 - \Phi(1.25) = 0.1 \end{aligned}$$

- b. Il livello di significatività osservato (p-value) è  $0.37 = P(\bar{Y} \geq \bar{y} | H_0)$ , quindi

$$0.37 = P\left(Z \geq \frac{\bar{y} - 55}{8/\sqrt{16}}\right) = 1 - \Phi\left(\frac{\bar{y} - 55}{2}\right)$$

da cui si ricava

$$\frac{\bar{y} - 55}{2} = \Phi^{-1}(1 - 0.37) = \Phi^{-1}(0.63) = 0.33$$

dove il valore di  $z_{0.63} = \Phi^{-1}(0.63)$  si ricava dalla tavola della funzione di ripartizione della distribuzione normale standard. Quindi si ottiene  $\bar{y} = 55.66$ .

- c. La potenza del test è la probabilità di rifiutare  $H_0$  se effettivamente è vera l'ipotesi  $H_1$ , ovvero  $P(\bar{Y} > 57.5|H_1)$ . Segue che

$$0.8 = P(\bar{Y} > 57.5|H_1) = 1 - P\left(Z \leq \frac{57.5 - \mu_1}{8/\sqrt{16}}\right) = 1 - \Phi\left(\frac{57.5 - \mu_1}{2}\right)$$

$$\frac{57.5 - \mu_1}{2} = \Phi^{-1}(1 - 0.8) \Rightarrow \mu_1 = 57.5 - 2z_{0.2} = 59.2.$$