

Inferenza Statistica
Esame del 9 febbraio 2015
Tempo a disposizione 2 ore.

1. Il numero di chiamate al soccorso stradale che si verificano giornalmente segue una legge di Poisson. Tuttavia è noto che in media nei giorni feriali arrivano il doppio delle chiamate rispetto a sabato e domenica. In un campione di giorni si sono osservate le chiamate e in 65 giorni feriali si sono avute in totale 132 chiamate. Nei 15 giorni festivi le chiamate sono state in totale 56.
- a. Si fornisca la stima di massima verosimiglianza delle chiamate medie giornaliere nei giorni festivi.
- b. Si verifichi se lo stimatore ottenuto al punto a. è corretto.
- c. Si fornisca una stima della probabilità che in un giorno feriale arrivino 2 o più chiamate.

Soluzione

- a. Si consideri il campione Y_1, \dots, Y_n , dove $n = n_1 + n_2$, $n_1 = 65, n_2 = 15$; Y_i ($i = 1, \dots, n_1$) sono variabili aleatorie di Poisson indipendenti di media 2λ , $n - n_1$ sono variabili aleatorie di Poisson indipendenti, ciascuna con valore atteso λ . La funzione di verosimiglianza per il campione (y_1, \dots, y_n) è

$$\begin{aligned} f(y_1, \dots, y_n; \lambda) &= L(\lambda) = \prod_{i=1}^{n_1} \frac{e^{-2\lambda} (2\lambda)^{y_i}}{y_i!} \prod_{i=n_1+1}^{n_1+n_2} \frac{e^{-\lambda} (\lambda)^{y_i}}{y_i!} \\ &= \frac{(2\lambda)^{\sum_{i=1}^{n_1} y_i} e^{-2n_1\lambda}}{y_1! \cdots y_{n_1}!} \frac{\lambda^{\sum_{i=n_1+1}^{n_1+n_2} y_i} e^{-n_2\lambda}}{y_{n_1+1}! \cdots y_{n_1+n_2}!}. \end{aligned}$$

Passando al logaritmo, si ha

$$l(\lambda) = \sum_{i=1}^{n_1} y_i \log(2\lambda) - 2n_1\lambda - \log c_1 + \sum_{i=n_1+1}^{n_1+n_2} y_i \log(\lambda) - n_2\lambda - \log c_2$$

dove $c_1 := y_1! \cdots y_{n_1}!$ e $c_2 := y_{n_1+1}! \cdots y_{n_1+n_2}!$ non dipendono da λ . Derivando si trova che

$$\frac{d}{d\lambda} l(\lambda) = \frac{1}{\lambda} \sum_{i=1}^{n_1} y_i - 2n_1 + \frac{1}{\lambda} \sum_{i=n_1+1}^{n_1+n_2} y_i - n_2.$$

Infine, eguagliando a zero la funzione *score* e risolvendo rispetto a λ si ha

$$\hat{\lambda}_{MV} = \frac{\sum_{i=1}^{n_1} y_i + \sum_{i=n_1+1}^{n_1+n_2} y_i}{2n_1 + n_2}$$

b. $E(\hat{\lambda}_{MV}) = \frac{1}{2n_1 + n_2} \left(\sum_{i=1}^{n_1} E(Y_i) + \sum_{i=n_1+1}^{n_1+n_2} E(Y_i) \right) = \frac{1}{2n_1 + n_2} (2n_1\lambda + n_2\lambda) = \lambda.$

Pertanto lo stimatore trovato è corretto.

- c. Si denoti con p la probabilità che in un giorno feriale arrivino 2 o più chiamate. Allora $p = P(Y \geq 2)$, $Y \sim Po(2\lambda)$. Lo stimatore di MV della probabilità p è

$$\hat{p}_{MV} = 1 - P(Y < 2) = 1 - P(Y = 0) - P(Y = 1) = 1 - e^{-2\hat{\lambda}_{MV}} - 2\hat{\lambda}_{MV}e^{-2\hat{\lambda}_{MV}},$$

in virtù della proprietà di equivarianza degli stimatori di MV. Essendo $\hat{\lambda} = \frac{132 + 56}{145} = 1.297$ la stima di massima verosimiglianza per λ , si ottiene $\hat{p} = 0.73$, dall'espressione sopra riportata.

2. Siano ${}_AY$ e ${}_BY$ le lunghezze dei chiodi prodotti da due diverse aziende, A e B. Si dispone di un campione casuale di 10 elementi dall'azienda A dal quale risulta:

$$10{}_A\bar{y} = \sum_i^{10} {}_Ay_i = 20; \quad \sum_i^{10} ({}_Ay_i - {}_A\bar{y})^2 = 20$$

Dalla seconda azienda si ha un campione di 6 elementi e si trova

$$6{}_B\bar{y} = \sum_i^6 {}_By_i = 13.2; \quad \sum_i^6 ({}_By_i - {}_B\bar{y})^2 = 20.5$$

Si voglia verificare l'ipotesi che le lunghezze medie delle due produzioni siano uguali contro l'alternativa che siano diverse.

- a. Si supponga dapprima che varianze delle lunghezze delle viti nelle due popolazioni siano ignote. Sotto quali assunzioni si è in grado di verificare l'ipotesi data sopra? Nel caso sia possibile, condurre la verifica di ipotesi al livello $\alpha = 0.02$.
- b. Per il caso al punto a. stabilire se il relativo p-value è superiore o inferiore a 0.1.
- c. Se invece le varianze fossero e pari a 3 e 4.5, rispettivamente, quali assunzioni sarebbero necessarie per condurre la verifica di ipotesi di uguaglianza fra le medie? Sotto tali condizioni, si ottenga il p-value per la verifica di ipotesi data sopra.

Soluzione

- a. Supponendo che le varianze σ_A^2 e σ_B^2 siano ignote, si assuma che i campioni di cui si dispone di ampiezza $n_A = 10$ e $n_B = 6$, rispettivamente, siano indipendenti e provenienti da popolazioni normali con varianze non note e uguali $\sigma_A^2 = \sigma_B^2 = \sigma^2$. Si vuole verificare l'ipotesi

$$H_0 : \mu_A - \mu_B = 0$$

contro l'alternativa $H_1 : \mu_A - \mu_B \neq 0$ al livello $\alpha = 0.02$. Le medie campionarie sono

$${}_A\bar{y} = \sum_i^{10} {}_Ay_i / 10 = 2, \quad {}_B\bar{y} = \sum_i^6 {}_By_i / 6 = 2.2$$

Sotto l'ipotesi nulla H_0 , si ha che la statistica T ha distribuzione t di Student con $n_A + n_B - 2 = 14$ gradi di libertà:

$$T = \frac{{}_A\bar{Y} - {}_B\bar{Y}}{S_p \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} \sim t_{14}$$

dove

$$S_p = \sqrt{\frac{\sum_{i=1}^{10} (Ay_i - A\bar{y})^2 + \sum_{i=1}^6 (By_i - B\bar{y})^2}{n_A + n_B - 2}}$$

è lo stimatore della varianza comune nell'ipotesi di omoschedasticità. Poiché si tratta di un test bilaterale, la zona di rifiuto del test basata sul valore osservato t di T è data da $R = \{t : |t| \geq t_{1-\alpha/2}\}$. Dai dati campionari si trova

$$t = \frac{2 - 2.2}{\sqrt{\frac{20+20.5}{14} \left(\frac{1}{10} + \frac{1}{6}\right)}} = -0.23.$$

ed essendo $|t| < t_{1-\alpha/2} = t_{0.99,14} = 2.624$, si decide di non rifiutare H_0 al livello del 2%.

b. Il p-value per il test al punto **a.** è calcolato come

$$\gamma = P(|T| \geq |t| | H_0) = 2(1 - P(T \leq 0.23))$$

con $T \sim t_{14}$. Dalle tavole si trova che $t_{1-0.1/2,14} = t_{0.95,14} \approx 1.76$, pertanto $P(T > 0.23)$ è molto maggiore di 0.05 e quindi il p-value dato da $2P(T > 0.23)$ è molto maggiore di 0.1 (se si ricorresse all'uso di R, si troverebbe $\gamma \approx 0.82$ confermando che i dati non danno evidenza contro H_0).

c. Assumendo che i due campioni provengano da popolazioni distribuite normalmente con medie μ_A, μ_B e varianze $\sigma_A^2 = 3$ e $\sigma_B^2 = 4.5$, si ha che, sotto H_0 ,

$$Z = \frac{A\bar{Y} - B\bar{Y}}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} \sim N(0, 1)$$

e dai dati si ottiene il valore

$$z = \frac{2 - 2.2}{\sqrt{\frac{3}{10} + \frac{4.5}{6}}} = -0.195.$$

Data la regione di rifiuto del test $R = \{z : |z| \geq 2.326\}$, si ha che $z \notin R$, e quindi l'ipotesi nulla non viene rifiutata al livello del 2%. Il p-value è dato da

$$\begin{aligned} P(|Z| \geq |z| | H_0) &= 2P(Z \geq 0.195) \\ &= 2(1 - \Phi(0.195)) \\ &= 0.85. \end{aligned}$$

3. Per verificare la durata delle lampadine prodotte da un'azienda si registrano i tempi di funzionamento (in giorni) per un campione casuale semplice di 190 lampadine. La tabella che segue riporta i dati ottenuti.

Durata in giorni	da 0 a 11	da 11 a 22	da 22 a 33	oltre 33
Frequenze	118	47	12	13

Sia inoltre noto che la somma delle durate di tutte le lampadine che durano oltre 33 giorni è pari a 537 giorni.

a. Si verifichi l'ipotesi che i tempi di durata delle lampadine sono distribuiti secondo una legge esponenziale (al livello $\alpha = 0.05$).

- b.** Si dica se il p-value per il test del punto **a.** è superiore a 0.2.

Soluzione

- a.** Si tratta di verificare l'ipotesi che la variabile Y che descrive i tempi di durata delle lampadine segua la distribuzione esponenziale:

$$H_0 : f(y; \lambda) = \lambda e^{-\lambda y}, \quad y > 0$$

Occorre prima stimare λ . la stima di massima verosimiglianza di λ con i dati del campione osservato è il reciproco della media ponderata dei dati del campione. Posto $n = 190$, denotate con n_i le frequenze osservate e con \tilde{y}_i i valori centrali in ogni classe, si ha

$$\bar{y} = \frac{1}{n} \sum_{i=1}^4 n_i \tilde{y}_i = \frac{118(11/2) + 47((11+22)/2) + 12((22+33)/2) + 537}{190} = 12.06053$$

Pertanto la stima di massima verosimiglianza di λ è $\hat{\lambda} = 1/12.06053 = 0.083$.

Le frequenze relative possono ora essere calcolate in corrispondenza di ciascuna classe. Ad esempio, per la classe 11 – 22 si ha

$$P(11 \leq X \leq 22) = F(22) - F(11) = 1 - e^{-0.083 \cdot 22} - (1 - e^{-0.083 \cdot 11}) = 0.240$$

e la corrispondente frequenza attesa è $n \times 0.240 = 45.6$. I dati ottenuti sono riportati nella tabella seguente.

Durata in giorni	Freq. oss. n_i	Freq. relative p_{i0}	Freq. attese $n \cdot p_{i0}$
da 0 a 11	118	0.599	113.81
da 11 a 22	47	0.240	45.6
da 22 a 33	12	0.096	18.24
>33	13	0.065	12.35
Tot	190	1	190

Per condurre la verifica di ipotesi calcoliamo infine

$$\chi^2 = \frac{(118 - 113.81)^2}{113.81} + \frac{(47 - 45.6)^2}{45.6} + \frac{(12 - 18.24)^2}{18.24} + \frac{(13 - 12.35)^2}{12.35} = 2.37.$$

Posto $\alpha = 0.05$ l'ipotesi nulla non viene rifiutata poiché $\chi^2 = 2.37 < \chi_{1-0.05,2}^2 = 5.99$ (i gradi di libertà sono $(4-1)-1=2$, essendo uno il parametro stimato con i dati del campione).

- b.** Il p-value per il test al punto **a.** è espresso da $P(Y \geq 2.37)$, dove $Y \sim \chi_2^2$. Dalle tavole si trova che $P(Y \geq 1.39) \approx 0.5$ e $P(Y \geq 2.77) \approx 0.25$, per cui la $P(Y \geq 2.37)$ sarà poco superiore a 0.25, e certamente compresa tra 0.25 e 0.5 (utilizzando R si trova che tale valore è 0.31).

- 4.** I rendimenti annuali di tre titoli azionari X , Y e Z sono variabili aleatorie Gaussiane le cui medie sono rispettivamente 0.02, 0.01 e 0.05 e le varianze sono pari a 0.003, 0.001, 0.005. La matrice di correlazione è

$$\rho = \begin{bmatrix} 1 & 0.5 & 0.3 \\ 0.5 & 1 & 0.2 \\ 0.3 & 0.2 & 1 \end{bmatrix}$$

- a.** Calcolare la probabilità che un portafoglio di titoli costituito per il 60% da azioni X e per il 40% da azioni Y abbia rendimento totale positivo.

- b.** Ha più probabilità di rendimento positivo il portafoglio definito sopra oppure uno composto esclusivamente da azioni Z ?

Soluzione

- a.** Si denoti con R il rendimento di un portafoglio costituito per il 60% da azioni X e per il 40% da azioni Y , pertanto $R = 0.6R_X + 0.4R_Y$, dove $R_X \sim N(0.02, 0.003)$ ed $R_Y \sim N(0.01, 0.001)$ rappresentano i rendimenti annuali dei titoli X e Y , rispettivamente.

Poiché R è combinazione lineare di v.a. normali, si ricava che R sarà distribuita normalmente con

$$E(R) = 0.6 \cdot E(R_X) + 0.4 \cdot E(R_Y) = 0.016,$$

$$V(R) = 0.6^2 \cdot V(R_X) + 0.4^2 \cdot V(R_Y) + 2 \cdot 0.6 \cdot 0.4 \cdot Cov(R_X, R_Y) = 0.00304,$$

essendo $Cov(R_X, R_Y) = \rho_{XY} \sqrt{V(R_X)V(R_Y)} = 0.0009$. La probabilità richiesta è data da

$$P(R > 0) = 1 - P\left(Z < \frac{0 - 0.016}{\sqrt{0.00304}}\right) = 1 - \Phi(-0.29) \approx 0.61,$$

dove con Z si denota una variabile casuale normale standardizzata e $\Phi(\cdot)$ è la sua funzione di ripartizione.

- b.** Un portafoglio composto esclusivamente da azioni Z ha rendimento positivo con probabilità

$$P(R_Z > 0) = 1 - \Phi\left(\frac{0 - E(R_Z)}{\sqrt{V(R_Z)}}\right) = 1 - \Phi\left(\frac{0 - 0.05}{\sqrt{0.005}}\right) = 1 - \Phi(-0.707) \approx 0.76 > 0.61.$$